

Análise Multivariada II

LISTA V - ANÁLISE DISCRIMINANTE (AD)

Breno Cauã Rodrigues da Silva

Os dados do arquivo “Jogadores.xls” foram coletados por G. R. Bryce e R. M. Barker (Apresentados em Rencher, 2002) como parte de um estudo preliminar sobre uma possível relação entre o design do capacete de futebol americano e lesões no pescoço. Seis medidas da cabeça foram feitas em cada sujeito. Havia 30 sujeitos em cada um dos três grupos: jogadores de futebol americano do ensino médio (grupo 1), jogadores de futebol americano universitário (grupo 2) e não jogadores de futebol americano (grupo 3). As seis variáveis são:

- Larg_cab: Largura da cabeça na dimensão mais larga;
- Circ_cab: Circunferência da cabeça;
- Frent_tras: Medida da frente para trás na altura dos olhos;
- Olh_cab: Medida do olho ao topo da cabeça;
- Ore_cab: Medida da orelha ao topo da cabeça;
- Larg_quei: Largura da mandíbula.

1) Realize a análise exploratória de dados, apresentando a análise geral e por grupos (apresente tabelas e gráficos).

A primeira proposta de análise foi elaborada na Tabela 1, que apresenta as medidas de resumo das variáveis do conjunto de dados Jogadores.xls. A Tabela 1 não leva em consideração a variável de grupo.

Tabela 1: Medidas de Resumo para as Variáveis do Conjunto de Dados Jogadores.xlsx.

Variável	Média	Desvio Padrão	CV	Mínimo	1º Quartil	Mediana	3º Quartil	Máximo
Circu_cab	58,04	1,88	3,25%	54,8	56,90	57,55	59,15	63,5
Frent_tras	19,91	0,75	3,75%	18,5	19,42	19,90	20,40	21,8
Larg_cab	15,40	0,67	4,32%	13,5	15,00	15,50	15,65	17,5
Larg_quei	12,00	0,64	5,30%	10,5	11,50	12,00	12,50	13,5
olh_cab	11,37	1,68	14,76%	7,4	10,12	11,30	12,73	15,0
ore_cab	13,96	0,96	6,85%	11,1	13,40	13,90	14,50	16,5

Podemos observar que, em termos de dispersão, a variável *olh_cab* (Medida do olho ao topo da cabeça) possui o maior Desvio Padrão em proporção à sua Média (14,76%), indicando uma variabilidade relativamente alta em comparação com outras medidas como *Circu_cab* (Circunferência da cabeça), que tem uma variabilidade proporcional menor (3,25%). Outro ponto é a proximidade entre a Média e a Mediana para a maioria das variáveis (ex: *Frent_tras*, Média=19,91 e Mediana=19,90) sugere distribuições razoavelmente simétricas.

Uma outra análise visual univariada pode ser feita a partir da Figura 1. Onde é apresentado o histograma para cada variável do *dataset* analisado.




Figura 1: Histograma das Variáveis Quantitativas do Conjunto de Dados Jogadores.xls.

Os histogramas oferecem uma primeira visão sobre a distribuição de cada variável, ainda sem separação por grupo. Os histogramas de (a), (c) e (f) aparentam ser uma forma ligeiramente simétrica com uma concentração de dados em torno do centro - lembrando uma distribuição gaussiana.

Apenas as variáveis de (d) e (e) se distanciam desse realidade de forma mais grosseira, com histogramas que lembram mais uma *distribuição bimodal* (com dois picos claros), isso é um forte indicativo de que os dados, quando vistos de forma agregada, escondem a existência de pelo menos dois subgrupos com características distintas. Essa observação justifica plenamente a necessidade de analisar os dados por grupo. Uma conclusão feita em (b) é que a variável *Circu_cab* mostra uma leve assimetria à direita.

Visando uma análise global juntamente da finalidade deste relatório, foi elaborada a Tabela 2, que recalcula as medidas de resumo por grupo para cada uma das variáveis.

Tabela 2: Medidas de Resumo para as Variáveis do Conjunto de Dados Jogadores.xlsx por Grupo.

Grupo	Média	Desvio Padrão	CV	Mínimo	1º Quartil	Mediana	3º Quartil	Máximo
Circu_cab								
1	58,95	2,05	3,48%	55,9	57,20	58,40	60,67	63,5
2	57,39	1,71	2,98%	54,8	56,50	57,00	58,00	62,6
3	57,77	1,55	2,68%	55,0	56,75	57,65	58,65	61,7
Frent_tras								
1	20,11	0,84	4,19%	19,0	19,50	20,00	20,88	21,8
2	19,80	0,74	3,75%	18,5	19,30	19,90	20,20	21,5
3	19,81	0,62	3,11%	18,7	19,50	19,80	20,38	20,8
Larg_cab								
1	15,20	0,74	4,86%	13,5	15,00	15,50	15,50	17,5
2	15,42	0,64	4,13%	14,3	15,12	15,40	15,50	17,3
3	15,58	0,58	3,71%	14,6	15,30	15,50	15,90	17,3
Larg_quei								
1	12,27	0,69	5,64%	10,5	12,00	12,25	12,50	13,5
2	11,94	0,61	5,14%	10,5	11,53	11,90	12,38	13,3
3	11,80	0,52	4,41%	10,8	11,50	11,75	12,10	13,3
olh_cab								
1	13,08	1,04	7,97%	10,0	12,50	13,00	13,88	15,0
2	10,08	1,07	10,65%	8,2	9,45	9,90	10,47	12,8
3	10,95	1,21	11,03%	7,4	10,40	10,90	11,78	13,1
ore_cab								
1	14,73	0,94	6,41%	13,0	14,00	14,50	15,50	16,5
2	13,45	0,76	5,61%	11,1	12,85	13,45	14,05	14,5
3	13,70	0,63	4,57%	12,0	13,40	13,65	13,97	15,1

A Tabela 2 aprofunda a análise ao calcular as mesmas medidas de resumo, mas agora segmentadas para cada um dos três grupos: jogadores do ensino médio (1), jogadores universitários (2) e não jogadores (3). As principais diferenças observadas:

- As variáveis **olh_cab** (Olho ao topo da cabeça), **ore_cab** (Orelha ao topo da cabeça) e **Circu_cab** (Circunferência da cabeça) apresentam diferenças entre os grupos ao olharmos para média e mediana de cada uma delas. Sendo que existe um padrão nessa diferença de grupos, pois, o Grupo 1 apresenta estatísticas maiores que o Grupo 3 que, por sua vez, apresenta estatísticas maiores que o Grupo 2.
- Em contra-partida, **Frent_tras** (Frente para trás), **Larg_cab** (Largura da cabeça na dimensão mais larga) e **Larg_quei** (argura da mandíbula) mostraram estatísticas muito próximas entre os três grupos, indicando que ela provavelmente tem baixo poder para discriminar os grupos.

No entanto, é importante ressaltar que as conclusões são baseadas em uma análise descritiva dos dados. Tendo em vista que as disparidades existentes entre os grupos não são de alta magnitude em todas as variáveis, para afirmar que os grupos de fato diferem entre si, poderíamos aplicar, por exemplo, uma MANOVA.

Por fim, foi desenhada a Figura 2. Podemos avaliar a diferença entre os grupos dentro das variáveis de uma forma visual por meio de Boxplots.




Figura 2: Boxplot das Variáveis do Conjunto de Dados Jogadores.xlsx por Grupo.

Os boxplots da Figura 2 permitem uma comparação visual direta da distribuição das variáveis entre os grupos, confirmando e reforçando as observações da análise das medidas de resumo da Tabela 2. As variáveis **olh_cab**, **ore_cab** e **Circu_cab** demonstram as diferenças mais nítidas: as “caixas” do Grupo 1 estão posicionadas visivelmente acima das caixas dos Grupos 2 e 3, indicando pouca sobreposição. Visualmente, **olh_cab** parece ser a variável com maior poder de discriminação. Essa clara separação entre os grupos para ambas as variáveis explica a bimodalidade - das variáveis **olh_cab** e **ore_cab** - e assimetria - da variável **Circu_cab** - observada nos histogramas da Figura 1.

Em contrapartida, as demais variáveis mostram um poder de distinção menor. **Frent_tras**, por exemplo, apresenta boxplots quase perfeitamente alinhados, confirmando sua baixa capacidade de diferenciar os grupos. As outras medidas também exibem sobreposição considerável, apesar de algumas diferenças nas medianas e na presença de valores discrepantes (outliers) no gráfico.

De modo a fechar a análise exploratória e confirmar tudo o que já foi dito, foi elaborado a Figura 3.




Figura 3: Pairplot do Conjunto de Dados Segmentadas pelo Grupo de Jogadores.

NOTA: A título de bônus para a Questão 2, e como complemento à Análise Exploratória de Dados, será executada uma Análise de Variância Multivariada (MANOVA) com o objetivo de verificar a existência de diferenças estatisticamente significativas entre os grupos.

2) Faça testes de normalidade multivariada e teste de homogeneidade de variância.

A Análise Discriminante apresenta os seguintes pressupostos:

1. Normalidade Multivariada das observações;
2. Matrizes de Covariâncias dos grupos deve ser iguais.

Desta forma, para verificar a *Normalidade Multivariada*, foram aplicados os Testes de Normalidade de Mardia, Henze-Zirklers e de Royston sob as hipóteses:

$$\begin{cases} H_0 : \text{Os dados seguem uma distribuição normal multivariada;} \\ H_1 : \text{Os dados não seguem uma distribuição normal multivariada.} \end{cases}$$

Veja a Tabela 3, Tabela 4, Tabela 5.

Tabela 3: Teste de Mardia para Normalidade Multivariada.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Mardia Skewness	84,869	0,008	asymptotic	Not normal
Mardia Kurtosis	0,927	0,354	asymptotic	Normal

Tabela 4: Teste de Henze-Zirkler para Normalidade Multivariada.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Henze-Zirkler	0,941	0,228	asymptotic	Normal

Tabela 5: Teste de Royston para Normalidade Multivariada.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Royston	30,218	<0.001	asymptotic	Not normal

De certa forma houve empate entre os testes apresentados pela Tabela 3, Tabela 4, Tabela 5. Para corrigir isso foi, primeiramente, realizado o Teste de Shapiro-Wilk para normalidade univariada. Os resultados estão disponíveis na Tabela 6.

Tabela 6: Teste de Shapiro-Wilk para Normalidade Univariada.

Variável	Estatística W	Valor p	Normalidade
Larg_cab	0,9464	0,0010	Not normal
Circu_cab	0,9453	0,0009	Not normal
Frent_tras	0,9797	0,1723	Normal
olh_cab	0,9832	0,2967	Normal
ore_cab	0,9727	0,0548	Normal
Larg_quei	0,9857	0,4338	Normal

Foi constatada a não normalidade apenas às variáveis Larg_cab e Circu_cab. Com isso, foi aplicada transformação de Box-Cox com o parâmetro λ estimado por máxima verossimilhança (λ ótimo), dada pela seguinte expressão:

$$Y^{(\lambda)} = \frac{Y^\lambda - 1}{\lambda}.$$

Foi usada a seguinte sintaxe no R:

```
# -----
# [2.2] TRANSFORMAÇÃO BOX-COX
# -----
Players.trf <- 1 * Players

m1.for.boxcox <- lm(formula = Larg_cab ~ 1, data = Players.trf)
r1.boxcox <- MASS::boxcox(m1.for.boxcox, lambda = seq(-4, 4, by = 0.01))
lambda1.optim <- r1.boxcox$x[which.max(r1.boxcox$y)]
```

```

Players.trf$Larg_cab <- (Players.trf$Larg_cab^lambda1.optim - 1) / lambda1.optim

m2.for.boxcox <- lm(formula = Circu_cab ~ 1, data = Players.trf)
r2.boxcox <- MASS::boxcox(m2.for.boxcox, lambda = seq(-4, 4, by = 0.01))
lambda2.optim <- r1.boxcox$x[which.max(r2.boxcox$y)]
Players.trf$Circu_cab <- (Players.trf$Circu_cab^lambda2.optim - 1) / lambda2.optim

```

Desta forma, foi aplicado novamente o Teste de Shapiro-Wilk para normalidade univariada com resultados dispostos na Tabela 7. E posteriormente os Testes de Normalidade Multivariada apresentados na Tabela 8, Tabela 9, Tabela 10.

Tabela 7: Teste de Shapiro-Wilk para Normalidade Univariada.

Variável	Estatística W	Valor p	Normalidade
Larg_cab	0,9530	0,0026	Not normal
Circu_cab	0,9746	0,0754	Normal
Frent_tras	0,9797	0,1723	Normal
olh_cab	0,9832	0,2967	Normal
ore_cab	0,9727	0,0548	Normal
Larg_quei	0,9857	0,4338	Normal

Tabela 8: Teste de Mardia para Normalidade Multivariada para os Dados Transformados.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Mardia Skewness	73,966	0,054	asymptotic	Normal
Mardia Kurtosis	0,504	0,615	asymptotic	Normal

Tabela 9: Teste de Henze-Zirkler para Normalidade Multivariada para os Dados Transformados.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Henze-Zirkler	0,921	0,357	asymptotic	Normal

Tabela 10: Teste de Royston para Normalidade Multivariada para os Dados Transformados.

Teste	Estatística de Teste	Valor p	Método	Normalidade
Royston	21,261	0,002	asymptotic	Not normal

Os resultados mostram que nem após a transformação Box-Cox a variável *Larg_cab* aderiu a distribuição normal. Entretanto, os testes de normalidade se mostraram mais concordantes entre si (adesão dos dados a normalidade multivariada), sendo que apenas o Teste de Royston apresentou resultado divergente. Agora, que os dados seguem uma distribuição normal multivariada, temos que verificar a *Homogeneidade/Homocedasticidade das Matrizes de Covariâncias*, foi aplicado o Teste M de Box sob as hipóteses:

$$\begin{cases} H_0 : \text{As matrizes de covariâncias são iguais;} \\ H_1 : \text{As matrizes de covariâncias não são iguais.} \end{cases}$$

Veja a Tabela 11.

Tabela 11: Teste M de Box para Homogeneidade das Matrizes de Covariâncias dos Grupos do Conjunto de Dados.

Estatística de Teste	Graus de Liberdade	P-Valor
55,79338	42	0,0753552

Como os pressupostos da Análise de Discriminante e Análise de Variância Multivariada são quase os mesmos, foi feita uma MANOVA para complemento da Análise Exploratória de Dados e para verificar se existe realmente diferença entre os grupos de forma estatisticamente significativa. Veja a Tabela 12.

Tabela 12: Análise de Variância Multivariada para o Fator Grupo de Jogadores.

Teste	gl	Estatística	$F \approx$	gl_{num}	gl_{den}	Valor p	Significância
Wilks	1	0,54	11,68	6	83	$1,91 \times 10^{-9}$	***
Pillai	1	0,46	11,68	6	83	$1,91 \times 10^{-9}$	***
Hotelling-Lawley	1	0,84	11,68	6	83	$1,91 \times 10^{-9}$	***
Roy	1	0,84	11,68	6	83	$1,91 \times 10^{-9}$	***

Significância: Rejeita-se H_0 para $\alpha = 0$ ('***'); $\alpha = 0.001$ (**); $\alpha = 0.01$ (*); $\alpha = 0.05$ ('.')

Pode-se observar que todos os testes apontam à mesma direção: a diferença significativa entre os grupos. Logo, prosseguiremos para a Análise de Discriminante.

3) Realize a análise discriminante utilizando todas as variáveis, apresente as funções discriminantes e a avaliação do modelo com a matriz de confusão e a acurácia (pelo menos).

Tabela 13: Coeficientes dos Discriminantes Lineares.

Variável	LD1	LD2
Larg_cab	117,8461	173,3276
Frent_tras	0,0004	-0,0125
olh_cab	-0,6443	0,5461
ore_cab	-0,5119	-0,3899
Larg_quei	-0,8301	-1,5138

A partir do modelo apresentado pela Tabela 13, foi feita uma previsão para os dados e, desta forma, construída a *Matriz de Confusão dada pela Tabela 14.

Tabela 14: Matriz de Confusão do Modelo de Discriminação Linear.

	Grupo 1	Grupo 2	Grupo 3
--	---------	---------	---------

Grupo 1	26	1	3
Grupo 2	1	20	9
Grupo 3	2	8	20

A partir da Tabela 14, foi calculada a acurácia (percentual de acerto) do modelo descrito pela Tabela 13. A acurácia obtida foi cerca de 73,33%.

- 4) Realize o procedimento stepwise e selecione um subgrupo de variáveis.**
- 5) Realize nova análise discriminante utilizando as variáveis selecionadas, apresente as funções discriminantes e a avaliação do modelo com a matriz de confusão e a acurácia (pelo menos).**
- 6) Pesquise uma função discriminante quadrática e realize mais uma AD com essa função, fazendo a avaliação do modelo (se desejar faça com todas as variáveis e com as selecionadas no stepwise, ou faça somente com as selecionadas).**
- 7) Compare as funções discriminantes em relação a matriz de confusão e acurácia e escolha a que você considera melhor.**