



Unidade VI – Análise de Agrupamento

6.1. Introdução

A Análise de Agrupamento, AA ou análise de cluster, é uma técnica multivariada que têm como objetivo agrupar casos (indivíduos) semelhantes segundo suas características (variáveis) podendo ser utilizada tanto para variáveis quantitativas quanto qualitativas. Pode ser feito também o agrupamento de variáveis semelhantes segundo os valores obtidos pelos casos (indivíduos). Essa abordagem é usualmente considerada não-paramétrica porque não há a necessidade de assumir uma distribuição ou um modelo específico. Em Inteligência Artificial essa técnica é tida como técnica de classificação enquadrada na categoria de algoritmos de Aprendizado não supervisionado (não tem uma variável resposta). Em áreas ligadas a Biologia, essa técnica é conhecida como taxonomia numérica.

Na análise de agrupamento os objetos (casos ou variáveis) semelhantes são alocados em um mesmo grupo e chamados similares e aqueles que pertencem a grupos distintos são chamados dissimilares. A semelhança entre os objetos é quantificada por meio de uma medida de proximidade, que engloba tanto as medidas de similaridade quanto as de dissimilaridade. Nas medidas de similaridade quanto maior for o valor mensurado, maior vai ser a semelhança entre os objetos e quanto mais a medida for próxima de zero, menor vai ser a semelhança entre os objetos. A interpretação para as medidas de dissimilaridade é o oposto, ou seja, quanto maior for o valor da medida, menor a semelhança entre os objetos.

Existem dois grandes grupos de métodos de Análise de agrupamento:

Métodos Hierárquicos - O agrupamento em classes procede por etapas, em geral começa com n subgrupos (um de cada observação) e termina com um único *cluster* contendo todas as n observações.

Métodos Não-Hierárquicos - Fixa-se, de início, o número k de classes que se pretende constituir e (regra geral) faz-se uma classificação inicial dos n indivíduos em k classes, ou determinam-se k “sementes” em torno das quais se devem construir as classes. Transferindo-se indivíduos de uma classe para outra, ou associando os indivíduos às sementes das classes, procura-se determinar uma “boa” classificação, no sentido de tornar as classes mais internamente homogêneas e externamente heterogêneas.

6.2. Medidas de proximidade

A proximidade entre os objetos será determinada por meio de medidas de distância que dependem do tipo de variável: quantitativa ou qualitativa. Após a escolha das variáveis que serão usadas como critérios de semelhança, uma das questões vitais das técnicas de análise de agrupamento, é a definição do coeficiente de similaridade ou dissimilaridade. Como a distância diminui à medida que as observações tornam-se mais parecidas, ela é chamada uma medida de dissimilaridade. Uma medida de similaridade é o coeficiente de correlação, cujo valor é maior quando as observações são mais similares. Vamos relembrar medidas de distância para variáveis quantitativas e qualitativas.

6.2.1 Variáveis quantitativas

Considere o vetor $\mathbf{x}$ de coordenadas reais $(x_1, x_2, \dots, x_p)$ como descritor dos objetos que investigarão os assemelhamentos. A medida mais conhecida para indicar a proximidade entre os objetos A e B é a **distância euclidiana** $d(A, B)$:

$$d(A, B) = \left[\sum_{i=1}^p (x_i(A) - x_i(B))^2 \right]^{1/2}$$

ou em linguagem matricial:

$$d(A, B) = [(\mathbf{x}(A) - \mathbf{x}(B))'(\mathbf{x}(A) - \mathbf{x}(B))]^{1/2}$$

Quando se trabalha com variáveis quantitativas, a distância euclidiana comumente soma distâncias não comparáveis, como cm, kg, anos, milhões, etc., muito embora, a mudança de uma das unidades possa alterar completamente o significado e o valor do coeficiente.

Essa é uma das razões da padronização das variáveis dos elementos $x_1, x_2, \dots, x_p$ do vetor $\mathbf{x}$. Assim o uso da transformação

$$z_i = \frac{x_i - \bar{x}}{s_i}$$

em que $\bar{x}_i$ e s_i , indicam respectivamente a média e o desvio padrão de i -ésima coordenada, é um dos modos para evitar essa inconveniência. Feita a transformação, a distância euclidiana passa a ser:

$$d(A,B) = \left[\sum_{i=1}^p (z_i(A) - z_i(B))^2 \right]^{1/2},$$

que é a soma dos desvios padronizados. É fácil verificar que a expressão acima pode ser escrita da seguinte forma, em notação vetorial:

$$d(A, B) = [(\mathbf{x}(A) - \mathbf{x}(B)) \mathbf{D}^{-1}(\mathbf{x}(A) - \mathbf{x}(B))]^{1/2}$$

onde $\mathbf{D}$ é uma matriz diagonal, tendo como i-ésimo componente a variância s_i^2 , isto é,

$$\mathbf{D} = \text{diag}(s_1^2, s_2^2, \dots, s_p^2)$$

Distância city block (Manhattan) que é calculada imaginando que se queira andar por quarteirões nas cidades:

$$d(A, B) = \sum_i |x_i(A) - x_i(B)|.$$

Distância de Minkowski que generaliza algumas distâncias:

$$d(A, B) = [\sum_i |x_i(A) - x_i(B)|^m]^{1/m}.$$

Para $m = 1$, ela se iguala à distância de Manhattan e para $m = 2$, ela torna-se a distância Euclidiana.

Distância de Mahalanobis – É uma distância estatística que considera as diferenças entre variâncias e correlações entre as variáveis. É invariante a mudança de escala em X e tem um importante papel em problemas de classificação:

$$d(A, B) = [(\mathbf{x}(A) - \mathbf{x}(B)) \mathbf{S}^{-1}(\mathbf{x}(A) - \mathbf{x}(B))]^{1/2}$$

onde $\mathbf{S}^{-1}$ é a inversa da matriz de variância e covariância amostral.

6.2.2 Variáveis qualitativas

Podem ser usadas medidas de concordância (matching measures) ou coeficientes de associação - através da codificação de k valores possíveis em k-1 variáveis dicotômicas.

Variáveis dicotômicas:

Tabela de contingência 2x2:

Variável A	Variável B		Total
	Sim	Não	
Sim	a	b	a+b
Não	c	d	c+d
Total	a+c	b+d	n=(a+b+c+d)

Coeficiente de concordância: representa a proporção de variáveis em que há concordância nos valores dos indivíduos A e B. Toma valores entre 0 e 1.

$$d(A, B) = \frac{a + b}{a + b + c + d}$$

Coeficiente de Jaccard: Alternativa quando os indivíduos registrem ausência em muitas variáveis.

$$d(A, B) = \frac{a}{a + b + c}$$

6.3 Métodos de Agrupamento

Os principais algoritmos de agrupamentos são os hierárquicos e não hierárquico (k –means). Pelo lado computacional, os métodos hierárquicos requerem muita memória. Os não hierárquicos são em geral mais rápidos e de simples implementação.

6.3.1. Método hierárquico: cria uma árvore hierárquica representando as relações entre as classes, e a partição final é criada com base nesta. Os agrupamentos são construídos através de um processo iterativo podendo ser divisivo, quando as classes são divididas sucessivamente ou aglomerativos, quando as classes se fundem sucessivamente.

Os métodos aglomerativos são mais utilizados do que os métodos divisivos, mas em quaisquer dos dois métodos, deve ser tomada uma decisão quanto ao número ótimo de clusters. O método divisivo é considerado menos eficiente do que o aglomerativo e também exige uma capacidade computacional maior porque ele começa com um agrupamento

formado por todos os casos e gradualmente vai dividindo em agrupamentos menores até finalizar com um agrupamento padrão. O método divisivo não será tratado na disciplina.

Para o método hierárquico aglomerativo deve-se combinar os dois grupos mais próximos a cada passo, então é necessário medir a proximidade (similaridade ou dissimilaridade) entre esses dois grupos.

Critérios de agrupamento Hierárquico aglomerativo

- a) **Vizinho mais próximo ou ligação simples** (*Nearest Neighbor or Single Linkage*) – a distância entre dois grupos A e B é calculada pelo mínimo das distâncias entre os pares formados pelos elementos em A e B. A cada passo é determinada a distância mínima e os grupos mais próximos são fundidos.

$$D(A, B) = \min\{d(x_i, x_j), \text{ para } x_i \text{ em } A \text{ e } x_j \text{ em } B\}$$

- b) **Vizinho mais distante ou ligação completa** (*Furthest Neighbor ou Complete Linkage*) – a distância entre dois grupos A e B é calculada pela distância máxima entre os pares formados pelos elementos de cada grupo. A cada passo é determinada a distância máxima para cada par de grupos e os dois grupos com a menor distância entre eles são fundidos.

$$D(A, B) = \max\{d(x_i, x_j), \text{ para } x_i \text{ em } A \text{ e } x_j \text{ em } B\}$$

- c) **Média das distâncias** – (*Average Linkage*) – a distância entre dois grupos A e B é calculada como a média das $n_A \cdot n_B$ distâncias entre n_A pontos em A e os n_B pontos em B.

$$D(A, B) = \frac{1}{n_A n_B} \sum_{i=1}^{n_A} \sum_{j=1}^{n_B} d(x_i, x_j),$$

e a cada passo são fundidos os dois grupos com a menor distância.

- d) **Centroíde** – distância entre dois grupos A e B é calculada pela distância euclidiana entre os vetores médios (frequentemente chamados centroides) dos dois grupos:

$$D(A, B) = d(\bar{x}_A, \bar{x}_B),$$

onde $\bar{x}_A$ e $\bar{x}_B$ são os vetores médios para as observações em A e em B respectivamente. Os dois grupos com a menor distância entre os seus centroides são fundidos a cada passo. Depois que dois grupos A e B são fundidos o centroíde do novo grupo AB é dado pela média ponderada:

$$\bar{x}_{AB} = \frac{n_A \bar{x}_A + n_B \bar{x}_B}{n_A + n_B}$$

- e) **Ward** – é chamado de método da soma de quadrados incremental ou método da variância mínima. Ele usa as distâncias quadradas intra-grupos (Within) e as distâncias entre-grupos (Between). Se AB é o novo grupo obtido pela combinação de A e B, então a soma de distâncias quadradas intra-grupo (das observações provenientes do vetor de médias do grupo) são:

$$\begin{aligned} SSE_A &= \sum_{i=1}^{n_A} (x_i - \bar{x}_A)'(x_i - \bar{x}_A) \\ SSE_B &= \sum_{i=1}^{n_B} (x_i - \bar{x}_B)'(x_i - \bar{x}_B) \\ SSE_{AB} &= \sum_{i=1}^{n_{AB}} (x_i - \bar{x}_{AB})'(x_i - \bar{x}_{AB}). \end{aligned}$$

O método de Ward agrega os dois grupos A e B que minimizam o incremento em SSE, definido como:

$$I_{AB} = SSE_{AB} - (SSE_A + SSE_B)$$

Procedimento

Os métodos hierárquicos requerem uma matriz contendo as métricas de proximidade entre os agrupamentos em cada estágio do algoritmo. Dessa forma, imaginando um estágio do algoritmo onde o número de agrupamentos corrente é três (G1, G2, G3), pode-se supor a seguinte matriz de distâncias entre os agrupamentos:

Exemplo: Matriz de Proximidades entre Grupos.

	G1	G2	G3
G1	0		
G2	0,1	0	
G3	0,3	0,4	0

Pela matriz ilustrativa acima se pode observar que

G1 e G2 são os agrupamentos mais similares, enquanto que G2 e G3 são os menos similares. São utilizados os métodos de distância entre grupos para o cálculo dos valores de proximidade entre os agrupamentos.

Depois de criada a matriz de proximidades, o próximo passo é encontrar o menor valor na matriz. Esse valor identifica os dois agrupamentos mais similares entre si. Feito isso, esses dois agrupamentos identificados são agrupados, formando assim um novo agrupamento. Logo em seguida, a matriz é atualizada, contendo agora um agrupamento a menos. Esse procedimento é feito até restar apenas um único agrupamento.

O procedimento geral pode ser descrito em poucos passos (Matteucci, 2005):

1. Início: Cada agrupamento contém um único elemento.
2. Calcular a matriz de proximidades.
3. Forma-se um novo agrupamento pela união dos grupos com maior grau de similaridade.
4. Os passos 2 e 3 são executados (n-1) vezes, até que todos os objetos estejam em um único agrupamento.

Exemplo 1 (BUSSAB; MIAZAKI; ANDRADE, 1990):

Pretende-se investigar, exploratoriamente, o histórico de crescimento da massa corpórea das pessoas. O pesquisador gostaria de escolher representantes “típicos” da população para tentar traçar diferentes históricos, através de questionários mais complexos. Desse modo seria conveniente classificar a população alvo em grupos homogêneos segundo alguma característica de interesse. Conseguida essa divisão, poder-se-ia restringir o estudo a um representante de cada grupo, obtendo resultados mais variados e menos custosos. Como ainda é uma fase exploratória o pesquisador decidiu usar as informações de seis pessoas de seu conhecimento como estudo piloto. A altura foi medida em centímetros e o peso em quilogramas. Os resultados estão na Tabela 1.

Tabela 1. Dados Pessoais de Seis Indivíduos do Estudo-Piloto

INDIVÍDUO	ALTURA	PESO	IDADE	INSTRUÇÃO	COR	SEXO
A	180	79	30	UNIV.	PRETA	M
B	175	75	28	UNIV.	BRANCA	M
C	170	70	20	SECUND.	BRANCA	F
D	167	63	25	UNIV.	PARDA	F
E	180	71	18	SECUND.	PARDA	M
F	165	60	28	PRIMÁRIO	BRANCA	F

Tratamento dos Dados

No estudo-piloto os objetos serão agrupados segundo duas características com unidades distintas (centímetro e quilograma), desse modo serão necessários alguns cuidados no instante de agrupar as informações. Assim, será usada a padronização estatística para as duas variáveis, ou seja, subtrair a média de cada observação e dividir pelo respectivo desvio-padrão. Os resultados são apresentados na Tabela 2.

Tabela 2. Construção dos Valores Padronizados do Peso e Altura do Estudo-Piloto.

INDIVÍDUO	ALTURA	PESO	ZALT	ZPES
A	180	79	1,10	1,31
B	175	75	0,33	0,75
C	170	70	-0,44	0,05
D	167	63	-0,90	-0,93
E	180	71	1,10	0,19
F	165	60	-1,21	-1,35
MÉDIA	172,8	69,7	0,0	0,0
DESVIO PADRÃO	6,5	7,1	1,0	1,0

Matriz de distâncias

Será utilizada a distância euclidiana para definir a ideia de proximidade, por exemplo, a distância entre os indivíduos A e B, será dada por:

$$d = [(z_1(A) - z_1(B))^2 + (z_2(A) - z_2(B))^2]^{1/2}$$

$$d = [(1,10 - 0,33)^2 + (1,31 - 0,75)^2]^{1/2} = 0,95$$

Aplicando esta fórmula para todos os pares da matriz Z, obtêm-se a matriz de proximidade D (matriz simétrica) derivada da matriz Z.

$$D = \begin{pmatrix} 0,00 & 0,95 & 1,99 & 3,00 & 1,12 & 3,52 \\ 0,95 & 0,00 & 1,05 & 2,08 & 0,95 & 2,60 \\ 1,99 & 1,05 & 0,00 & 1,09 & 1,54 & 1,60 \\ 3,00 & 2,08 & 1,09 & 0,00 & 2,29 & 0,52 \\ 1,12 & 0,95 & 1,54 & 2,29 & 0,00 & 2,77 \\ 3,52 & 2,60 & 1,60 & 0,52 & 2,77 & 0,00 \end{pmatrix}$$

Critério de agrupamento

Dependendo do critério utilizado pode-se chegar a resultados distintos de agrupamento. Os principais critérios utilizados na literatura são: ligação simples, ligação completa, centroide e Ward.

1) Critério do vizinho mais próximo ou de ligação simples (*Nearest Neighbor or Single Linkage*):

A distância entre os indivíduos será definida como: $D(A, B) = \min\{d(x_i, x_j), \text{para } x_i \text{ em } A \text{ e } x_j \text{ em } B\}$

Passo 1: Matriz de distâncias:

	A	B	C	D	E	F
A	0,00					
B	0,95	0,00				
C	1,99	1,05	0,00			
D	3,00	2,08	1,09	0,00		
E	1,12	0,95	1,54	2,29	0,00	
F	3,52	2,60	1,60	0,52	2,77	0,00

Passo 2: Escolher a menor distância para agrupar esses indivíduos. A menor distância é 0,52, então se deve agrupar D com F, ao nível 0,52. Os dois pontos são agrupados em um único obtendo agora 5 grupos: A, B, C, E, (DF). É necessário reconstruir a nova matriz de proximidade. Como os pontos A, B, C e E não sofreram alterações as distâncias entre eles também continuam as mesmas. A distância entre (DF) e os demais pontos será dada por:

$$d(A, DF) = \min\{d(A, D), d(A, F)\} = \min\{3,00; 3,52\} = 3,00$$

$$d(B, DF) = \min\{d(B, D), d(B, F)\} = \min\{2,08; 2,60\} = 2,08$$

$$d(C, DF) = \min\{d(C, D), d(C, F)\} = \min\{1,09; 1,60\} = 1,09$$

$$d(E, DF) = \min\{d(E, D), d(E, F)\} = \min\{2,29; 2,77\} = 2,29$$

que irá fornecer a seguinte matriz de distâncias:

	A	B	C	E	DF
A	0,00				
B	0,95	0,00			
C	1,99	1,05	0,00		
E	1,12	0,95	1,54	0,00	
DF	3,00	2,08	1,09	2,29	0,00

Passo 3: Analisando a nova matriz de similaridade nota-se que existem dois pares com a mesma proximidade A com B e B com E. Pode-se escolher qualquer par então se agrupa A com B ao nível 0,95, obtendo-se os seguintes grupos: C, E, (DF) e (AB). Como no caso anterior, as distâncias entre C, E e (DF) não se alteram. As distâncias de (AB) com os demais pontos serão:

$$d(C, AB) = \min\{d(C, A), d(C, B)\} = \min\{1,99; 1,05\} = 1,05$$

$$d(E, AB) = \min\{d(E, A), d(E, B)\} = \min\{1,12; 0,95\} = 0,95$$

$$d(DF, AB) = \min\{d(DF, A), d(DF, B)\} = \min\{3,00; 2,08\} = 2,08$$

a matriz resultante será:

	C	E	DF	AB
C	0,00			
E	1,54	0,00		
DF	1,09	2,29	0,00	

AB	1,05	0,95	2,08	0,00
----	------	------	------	------

Passo 4: Fundir AB com E, ao nível de 0,95, e recalculer as distâncias:

$$d(C, ABE) = \min\{d(C,AB), d(C,E)\} = \min\{1,05; 1,54\} = 1,05$$

$$d(DF, ABE) = \min\{d(DF,AB), d(DF,E)\} = \min\{2,08; 2,29\} = 2,08$$

Matriz resultante:

	C	DF	ABE
C	0,00		
DF	1,09	0,00	
ABE	1,05	2,08	0,00

Passo 5: Reunir C com ABE, ao nível de 1,05.

$$d(DF, ABEC) = \min\{d(DF,ABE), d(DF,C)\} = \min\{2,08; 1,09\} = 1,09$$

e tem-se a matriz:

	DF
ABEC	1,09


Passo 6: O último passo cria um único agrupamento contendo os 6 objetos, que serão similares a um nível de 1,09.

Resumindo, tem-se:

NÓ	FUSÃO	NÍVEL
1	D e F	0,52
2	A e B	0,95
3	AB e E	0,95
4	ABE e C	1,05
5	ABEC e DF	1,09

A sequência das agregações e as distâncias em que elas ocorrem são descritas no **dendrograma**, um gráfico útil na definição do número de agrupamentos. Ele representa a ordem em que os dados foram agrupados.

Dendrograma Ligação simples



2) Critério do vizinho mais distante ou de ligação completa (*Furthest Neighbor ou Complete Linkage*):

A distância entre os indivíduos será definida como: $D(A, B) = \max\{d(x_i, x_j), \text{ para } x_i \text{ em } A \text{ e } x_j \text{ em } B\}$

Convém ressaltar que a fusão ainda é feita com os grupos mais parecidos, menor distância.

Passo 1: Matriz de distâncias:

	A	B	C	D	E	F
A	0,00					

B	0,95	0,00				
C	1,99	1,05	0,00			
D	3,00	2,08	1,09	0,00		
E	1,12	0,95	1,54	2,29	0,00	
F	3,52	2,60	1,60	0,52	2,77	0,00

Passo 2: Escolher a menor distância para agrupar esses indivíduos. A menor distância é 0,52, então se deve agrupar D com F, ao nível 0,52. Os dois pontos são agrupados em um único obtendo agora 5 grupos: A, B C, E, (DF). É necessário reconstruir a nova matriz de proximidade. Como os pontos A, B, C e E não sofreram alterações as distâncias entre eles também continuam as mesmas. A distância entre (DF) e os demais pontos será dada agora por:

$$d(A, DF) = \max\{d(A,D), d(A,F)\} = \max\{3,00; 3,52\} = 3,52$$

$$d(B, DF) = \max\{d(B,D), d(B,F)\} = \max\{2,08; 2,60\} = 2,60$$

$$d(C, DF) = \max\{d(C,D), d(C,F)\} = \max\{1,09; 1,60\} = 1,60$$

$$d(E, DF) = \max\{d(E,D), d(E,F)\} = \max\{2,29; 2,77\} = 2,77$$

que irá fornecer a seguinte matriz de distâncias:

	A	B	C	E	DF
A	0,00				
B	0,95	0,00			
C	1,99	1,05	0,00		
E	1,12	0,95	1,54	0,00	
DF	3,52	2,60	1,60	2,77	0,00

Passo 3: Na nova matriz de similaridade agrupa-se B com E ao nível 0,95, obtendo-se os seguintes grupos: A, C, (DF) e (BE). As distâncias de (BE) com os demais pontos serão:

$$d(A, BE) = \max\{d(A,B), d(A,E)\} = \max\{0,95; 1,12\} = 1,12$$

$$d(C, BE) = \max\{d(C,B), d(C,E)\} = \max\{1,05; 1,54\} = 1,54$$

$$d(DF, BE) = \max\{d(DF,B), d(DF,E)\} = \max\{2,60; 2,77\} = 2,77$$

a matriz resultante será:

	A	C	DF	BE
A	0,00			
C	1,99	0,00		
DF	3,52	1,60	0,00	
BE	1,12	1,54	2,77	0,00

Passo 4: Fundir A com BE ao nível de 1,12, e recalculer as distâncias:

$$d(C, ABE) = \max\{d(C,A), d(C,BE)\} = \max\{1,99; 1,54\} = 1,99$$

$$d(DF, ABE) = \max\{d(DF,A), d(DF,BE)\} = \max\{3,52; 2,77\} = 3,52$$

Matriz resultante:

	C	DF	ABE
C	0,00		
DF	1,60	0,00	
ABE	1,99	3,52	0,00

Passo 5: Reunir C com DF, ao nível de 1,60.

$$d(CDF, ABE) = \max\{d(C,ABE), d(DF,ABE)\} = \max\{1,99; 3,52\} = 3,52$$


e tem-se a matriz:

	CDF
CDF	0,00

Passo 6: O último passo cria um único agrupamento contendo os 6 objetos, que serão similares a um nível de 3,52. Resumindo, tem-se:

NÓ	FUSÃO	NÍVEL
1	D e F	0,52
2	B e E	0,95
3	A E BE	1,12
4	C e DF	1,60
5	ABE e CDF	3,52

Que produzirá o Dendrograma:



1) Critério do centroide

Este processo é o mais direto deles, pois substitui cada fusão de objetos num único ponto representado pelas coordenadas de seu centro. A distância entre grupos é definida pela distância entre os centros. Em cada etapa procura-se fundir grupos que tenham a menor distância entre si.

Passo 1: O processo inicia com cada objeto alocado a um grupo. Portanto a distância entre os grupos é a distância entre os objetos, indicada pela matriz de distâncias:

	A	B	C	D	E	F
A	0,00					
B	0,95	0,00				
C	1,99	1,05	0,00			
D	3,00	2,08	1,09	0,00		
E	1,12	0,95	1,54	2,29	0,00	
F	3,52	2,60	1,60	0,52	2,77	0,00

Passo 2: A matriz das distâncias indica que os dois grupos mais parecidos são D e F, então eles serão fundidos dando origem ao grupo DF. A partir das coordenadas originais,

INDIVÍDUO	ZALT	ZPES
A	1,10	1,31
B	0,33	0,75
C	-0,44	0,05
D	-0,90	-0,93
E	1,10	0,19
F	-1,21	-1,35

serão calculadas as novas coordenadas do seu centro:

$$ZALT(DF) = (-0,90 - 1,21)/2 = -1,06 \text{ e}$$

$$ZPES(DF) = (-0,93 - 1,35)/2 = -1,14.$$

Novas Coordenadas:

GRUPOS	ZALT	ZPES
--------	------	------

A	1,10	1,31
B	0,33	0,75
C	-0,44	0,05
E	1,10	0,19
DF	-1,06	-1,14

De posse das novas coordenadas pode-se construir a nova matriz de distância. Observe que só irão mudar distâncias envolvendo o grupo DF. Assim,

$$D(A,DF) = \{ [(1,10 + 1,06)^2 + (1,31 + 1,14)^2] \}^{1/2} = 3,27$$

De modo análogo, obtém-se:

$$d(B, DF) = 2,35$$

$$d(C, DF) = 1,34$$

$$d(E,DF) = 2,54.$$

A nova matriz de distância entre os 5 grupos é:

	A	B	C	E	DF
A	0,00				
B	0,95	0,00			
C	1,99	1,05	0,00		
E	1,12	0,95	1,54	0,00	
DF	3,27	2,35	1,34	2,54	0,00

Passo 3: Daqui para frente o processo é iterativo. Assim, a fusão será entre A e B, produzindo:

$$ZALT(AB) = (1,10 + 0,33)/2 = 0,72$$

$$ZPES(AB) = (1,31 + 0,75)/2 = 1,03.$$

Com as novas coordenadas calculam-se as novas distâncias:

$$D(DF,AB) = \{ [(-1,06 - 0,72)^2 + (-1,14 - 1,03)^2]/2 \}^{1/2} = 1,98$$

$$\text{de modo análogo, } d(C, AB) = 1,07$$

$$d(E, AB) = 0,65$$

Novas Coordenadas

GRUPOS	ZALT	ZPES
C	-0,44	0,05
E	1,10	0,19
DF	-1,06	-1,14
AB	0,72	1,03

Matriz de Distâncias:

	C	E	DF	AB
C	0,00			
E	1,54	0,00		
DF	1,34	2,54	0,00	
AB	1,52	0,92	2,81	0,00

Passo 4: A fusão agora será entre AB e E (menor distância), dando origem ao grupo ABE. Voltando às coordenadas iniciais, obtém-se:

$$ZALT(ABE) = (1,10 + 0,33 + 1,10)/3 = 0,85$$

$$ZPES(ABE) = (1,31 + 0,75 + 0,19)/3 = 0,75.$$

e procedendo de modo análogo obtém-se:

Novas Coordenadas

GRUPOS	ZALT	ZPES
C	-0,44	0,05
DF	-1,06	-1,14
ABE	0,85	0,75

Matriz de Distâncias:

	C	DF	ABE
--	---	----	-----

C	0,00		
DF	1,34	0,00	
ABE	1,46	2,69	0,00

Passo 5: Fusão de C com DF, originando CDF, cujo centro será:

$$ZALT = (-0,44 - 0,90 - 1,21)/3 = -0,85$$

$$ZPES = (0,05 - 0,93 - 1,35)/3 = -0,74.$$

novamente deriva-se a matriz de distâncias.

Novas Coordenadas

GRUPOS	ZALT	ZPES
ABE	0,85	0,75
CDF	-0,85	-0,74


Matriz de Distâncias

	CDF
ABE	2,26

Passo 6: Finalmente reúne-se ABE com CDF, obtendo um único agrupamento contendo todos os objetos. Resumindo, tem-se o seguinte quadro do processo hierárquico:

NÓ	FUSÃO	NÍVEL
1	D e F	0,52
2	A e B	0,95
3	AB e E	0,92
4	C e DF	1,34
5	ABEC e CDF	2,26

Dendograma Ligação centroide



6.3.2. Métodos Não-Hierárquicos

As técnicas não-hierárquicas objetivam encontrar diretamente uma partição de n itens em k clusters, por 2 requisitos: semelhança interna e isolamento dos clusters formados. É necessário definir previamente o número de clusters desejado. Será estudado o método não-hierárquico de k-médias ou k-means.

Método k-Means

O método de k-means ou k-médias é um método considerado como um método baseado em partição e é atualmente bastante utilizado como uma das técnicas de mineração de dados. No método k-médias é necessário conhecer *a priori* o número de grupos k aos quais se deseja alocar os objetos. Além disso, diferente do procedimento hierárquico, no método k-médias o processo é aplicado à matriz de dados $\mathbf{X}$ e não à matriz de proximidade $\mathbf{D}$. Ele é visto na área de Computação muitas vezes como um método de otimização e não de partição porque o método consiste em alocar os objetos aos k grupos, já definidos, utilizando uma função objetivo como critério e a realocação termina quando uma regra de parada pré-estabelecida for atingida.

O método de k-médias é baseado nos seguintes passos:

Passo 1. Alocar arbitrariamente os n objetos aos k grupos e calcular os seus centroides, ou podem também gerar os centroides de cada grupo por um processo aleatório qualquer. Se for usado esse último processo, alocar cada um dos n objetos aos grupos que apresentam a menor distância euclidiana com o respectivo objeto. A distância entre o objeto e

o grupo é obtida geralmente por meio da distância euclidiana entre o vetor de observação do objeto e o centroide do grupo.

Passo 2. Recalcular os centroides de cada grupo.

Passo 3. Realocar o primeiro objeto de seu grupo para um outro grupo em que a distância euclidiana for menor que a distância desse objeto para o seu grupo de origem.

Passo 4. Repetir os passos 2 e 3 até que não ocorram mais mudanças de objetos de um grupo para outro.

Para iniciar o processo de agrupamento podem-se utilizar sementes aleatórias para representar o centroide dos k grupos ou ainda amostrar k objetos dentre os n originais para representar inicialmente as sementes ou centroides dos grupos. Aconselha-se repetir o processo com outras sementes ou centroides dos grupos e se as diferentes escolhas produzirem grupos finais muito distintos ou se a convergência for muito lenta, pode não haver grupos naturais no conjunto de dados.

Exemplo (FERREIRA, 2011): Agrupamento de 6 sistemas do uso da terra (SUT) dos solos da Amazônia mensurados em duas variáveis: areia e argila. Os dados médios de vários pontos amostrais em sistema de *grid* são apresentados a seguir. Considerar $k = 3$ grupos para aplicar o método k -médias.

SUT	Areia (Y_1)	Argila (Y_2)
Agricultura (A)	13,6	39,0
Agrofloresta (AG)	22,4	37,8
Floresta (F)	13,6	42,3
Capoeira Velha (CV)	13,2	39,5
Capoeira Nova (CN)	22,0	36,1
Pastagem (P)	28,2	32,5

Passo 1. Inicialmente foram agrupados os objetos de forma arbitrária: (A, AG), (F, CV), (CN, P). Os centroides dos três grupos foram calculados e estão apresentados a seguir:

Grupos de SUT	Média (Y_1)	Média (Y_2)
$G_1 = (A, AG)$	$(13,6+22,4)/2 = 18,0$	38,4
$G_2 = (F, CV)$	13,4	40,9
$G_3 = (CN, P)$	25,1	34,3

Calcula-se na sequência a distância euclidiana de cada objeto para o centroide do seu grupo e para o centroide dos demais grupos. Se a distância de um objeto em relação a um determinado grupo for menor do que a distância dele para o seu próprio grupo, o objeto deve ser realocado para o grupo de menor distância e recalculam-se os centroides após a realocação. Para o objeto A temos:

$$d(A, G_1) = \sqrt{(13,6 - 18,0)^2 + (39,0 - 38,4)^2} = 4,4407$$

$$d(A, G_2) = \sqrt{(13,6 - 13,4)^2 + (39,0 - 40,9)^2} = 1,9105$$

$$d(A, G_3) = \sqrt{(13,6 - 25,1)^2 + (39,0 - 34,3)^2} = 12,4234.$$

A menor distância encontrada para o objeto A foi entre ele e o grupo 2 (F, CV). O objeto A será então realocado para o G_2 e recalcula-se os centroides, conforme apresentado a seguir:

Grupos de SUT	Média (Y_1)	Média (Y_2)
$G_1 = (AG)$	22,4	37,8
$G_2 = (A, F, CV)$	13,5	40,3
$G_3 = (CN, P)$	25,1	34,3

Para o objeto A as distâncias aos centroides de cada grupo são:

$$d(A, G_1) = \sqrt{(13,6 - 22,4)^2 + (39,0 - 37,8)^2} = 8,8814$$

$$d(A, G_2) = \sqrt{(13,6 - 13,5)^2 + (39,0 - 40,3)^2} = 1,2737$$

$$d(A, G_3) = \sqrt{(13,6 - 25,1)^2 + (39,0 - 34,3)^2} = 12,4234.$$

Verifica-se que não houve realocação do objeto A, pois a menor distância é para o grupo 2 ao qual ele já está alocado. Passando ao objeto AG, ele possui distância nula para seu grupo pois o centroide do grupo é o seu próprio vetor de observação. As demais distâncias são apresentadas a seguir:

$$d(AG, G_2) = \sqrt{(22,4 - 13,5)^2 + (37,8 - 40,3)^2} = 9,2445$$

$$d(AG, G_3) = \sqrt{(22,4 - 25,1)^2 + (37,8 - 34,3)^2} = 4,4204.$$

Portanto, o objeto AG não será realocado. Considerando o objeto F, as distâncias aos grupos serão:

$$d(F, G_1) = \sqrt{(13,6 - 22,4)^2 + (42,3 - 37,8)^2} = 9,8838$$

$$d(F, G_2) = \sqrt{(13,6 - 13,5)^2 + (42,3 - 40,3)^2} = 2,0377$$

$$d(F, G_3) = \sqrt{(13,6 - 25,1)^2 + (42,3 - 34,3)^2} = 14,0089.$$

Novamente não há realocação, pois a menor distância é para o grupo que ele já está alocado (G_2). Para o objeto CV tem-se:

$$d(CV, G_1) = \sqrt{(13,2 - 22,4)^2 + (39,5 - 37,8)^2} = 9,3557$$

$$d(CV, G_2) = \sqrt{(13,2 - 13,5)^2 + (39,5 - 40,3)^2} = 0,8117$$

$$d(CV, G_3) = \sqrt{(13,2 - 25,1)^2 + (39,5 - 34,3)^2} = 12,9865.$$

E não vai haver realocação também. Passando ao objeto CN:

$$d(CN, G_1) = \sqrt{(22,0 - 22,4)^2 + (36,1 - 37,8)^2} = 1,7464$$

$$d(CN, G_2) = \sqrt{(22,0 - 13,5)^2 + (36,1 - 40,3)^2} = 9,4963$$

$$d(CN, G_3) = \sqrt{(22,0 - 25,1)^2 + (36,1 - 34,3)^2} = 3,5847.$$

Como a menor distância de CN foi ao grupo 1, ele deve ser realocado a esse grupo. Recalculando os centroides tem-se:

Grupos de SUT	Média (Y_1)	Média (Y_2)
$G_1 = (AG, CN)$	22,2	37,0
$G_2 = (A, F, CV)$	13,5	40,3
$G_3 = (P)$	28,2	32,5


Continuando os cálculos das distâncias euclidianas de cada objeto aos centroides dos grupos, obtém-se:

Grupos de SUT	Objeto					
	A	AG	F	CV	CN	P
$G_1 = (AG, CN)$	8,84	0,87	10,13	9,35	0,87	7,47
$G_2 = (A, F, CV)$	1,27	9,27	2,04	0,81	9,50	16,66
$G_3 = (P)$	15,98	7,85	17,58	16,55	7,17	0,00

Nenhum objeto deve ser realocado, pois as menores distâncias são entre o objeto e o grupo ao qual ele já está alocado. O agrupamento final será dado por: G_1 com os sistemas Agrofloresta e Capoeira Nova; G_2 com os sistemas Agricultura, Floresta e Capoeira Nova; e G_3 apenas como o sistema Pastagem.

Determinação do número de grupos

Nos métodos hierárquicos o número de grupos k é determinado pela escolha de um ponto de corte na escala de distância e fazendo o corte no dendrograma. O ponto de corte vai determinar o número de grupos e, portanto, a qualidade do agrupamento. Por exemplo, no exemplo cujo dendrograma é apresentado a seguir, pelo método de ligação simples, se for escolhido o ponto de corte igual a 1,06 (linha laranja), obteremos 2 grupos, mas se escolhermos o ponto de corte 0,90 (linha verde), serão 3 grupos.



Um critério proposto por Mojena (1977), *apud* Ferreira (2011) para determinar o número de grupos k que otimiza a qualidade do ajuste do agrupamento aos dados consiste em buscar a maior amplitude nas distâncias de junção dos grupos formados. No exemplo apresentado no dendrograma acima, a maior amplitude nos pontos de junção é dada na migração de 5 para 3 grupos com uma amplitude de 0,43 unidades (0,95 – 0,52). Na migração de 3 para 2 a amplitude foi de 0,10 unidades e de 2 para 1 de 0,04 unidades. Assim deve-se escolher $k = 3$ grupos.

Validação do agrupamento

A validação do agrupamento é a confirmação de que os grupos realmente diferem uns dos outros. Se os dados são provenientes de uma distribuição Normal multivariada, pode ser utilizada a Análise de Variância Multivariada (MANOVA) para verificar se os grupos diferem significativamente em relação aos seus centroides. Pode também ser usada uma análise discriminante na validação. Para agrupamentos hierárquicos pode ser utilizada na validação a correlação Cofenética. O coeficiente de correlação cofenética mede o grau de preservação das distâncias emparelhadas pelo dendrograma resultante do agrupamento em relação às distâncias originais. Pretende-se obter a correlação entre as distâncias observadas entre os objetos e as distâncias recuperadas na análise de agrupamento. A recuperação das distâncias entre os pares de objetos é feita a partir do dendrograma. Os $n(n-1)/2$ pares de distâncias, originais e recuperadas, são correlacionadas para a obtenção da matriz cofenética.

Exemplo: Calcular a correlação cofenética para o agrupamento de 5 objetos que foram avaliados em relação a 8 variáveis binárias utilizando a distância de Sokal-Michener:

Objetos	Variáveis							
	1	2	3	4	5	6	7	8
A	1	1	1	1	0	1	1	1
B	0	1	0	0	1	0	0	1
C	0	1	0	0	1	0	1	1
C	0	0	0	0	1	1	0	0
E	0	0	0	0	1	0	0	0

O agrupamento de variáveis binárias é realizado a partir da construção de tabelas de contingência entre os pares de objetos r e s , para os quais será calculada a distância de Sokal-Michener por meio da fórmula:

$$d_{rs} = \frac{a+d}{a+b+c+d}, \text{ na tabela de contingência:}$$

		Objeto 2		Totais
		1	0	
Objeto 1	1	a	b	$a+b$
	0	c	d	$c+d$
Totais		$a+c$	$b+d$	$p=a+b+c+d$

Para os objetos 1 e 2:

Objetos	Variáveis							
	1	2	3	4	5	6	7	8
1	1	1	1	1	0	1	1	1
2	0	1	0	0	1	0	0	1

Tem-se a tabela de contingência:

		Objeto 2		Totais
		1	0	
Objeto 1	1	$a=2$	$b=5$	7
	0	$c=1$	$d=0$	1
Totais		3	5	$p=8$

Logo a distância entre os objetos 1 e 2 será: $d_{12} = \frac{2}{8} = 0,250$

A matriz de distância calculada para todos os pares será:¹

¹ Calculada com o pacote clusterSim: `data(Dnominal)`
`ds <- dist.SM(Dnominal[-1])`

	1	2	3	4	5
1	0,000	0,750	0,625	0,875	1,000
2	0,750	0,000	0,125	0,375	0,250
3	0,625	0,125	0,000	0,500	0,375
4	0,875	0,375	0,500	0,000	0,125
5	1,000	0,250	0,375	0,125	0,000

Fazendo o agrupamento por ligação simples:

Passo 1: Matriz de distâncias:

	1	2	3	4	5
1	0,000				
2	0,750	0,000			
3	0,625	0,125	0,000		
4	0,875	0,375	0,500	0,000	
5	1,000	0,250	0,375	0,125	0,000

Passo 2: Escolher a menor distância para agrupar. A menor distância é 0,125, então se deve agrupar 2 com 3 (ou 4 com 5), ao nível 0,125. Grupos: 1, 4 5, 23.

Passo 3: Nova matriz de distâncias:

$d(1, 23) = \min\{d(1,2), d(1,3)\} = \min\{0,750; 0,625\} = 0,625$; $d(4,23) = 0,500$; $d(5,23) = 0,250$

	1	4	5	23
1	0,000			
4	0,875	0,000		
5	1,000	0,125	0,000	
23	0,625	0,500	0,250	0,000

Passo 4: Próxima fusão: 4 e 5 ao nível 0,125. Grupos: 1, 23, 45.

Passo 5: Nova matriz de distâncias:

$d(1,45) = \min\{0,875, 1\} = 0,875$; $d(23,45) = \min\{0,500, 0,250\} = 0,250$

	1	23	45
1	0,000		
23	0,625	0,000	
45	0,875	0,250	0,000

Passo 6: Próxima fusão: 23 e 45 ao nível 0,250. Grupos: 1, 2345.

Passo 7: Nova matriz de distâncias:

$d(1,2345) = \min\{0,625, 0,875\} = 0,625$.


	1	2345
1	0,000	
2345	0,625	0,000

Passo 8: Fusão final:

NÓ	FUSÃO	NÍVEL
1	2 e 3	0,125
2	4 e 5	0,125
3	23 e 45	0,250
4	1 e 2345	0,625

Dendrograma

Dendrograma Ligação simples



O agrupamento pode ser feito no R:

```
#Cluster com ligação simples
```

```
res.hcS <- hclust(ds, method = "single")
```

```
#Dendrograma
```

```
plot(res.hcS, labels = c("A", "B", "C", "D", "E"), cex = 0.6, hang = -1, main = "Dendrograma Ligação simples", ylab = "Ponto de fusão")
```

```
#Cluster com ligação completa
```

```
res.hcC <- hclust(ds, method = "complete")
```

```
#Dendrograma
```

```
plot(res.hcC, labels = c("A", "B", "C", "D", "E"), cex = 0.6, hang = -1, main = "Dendrograma Ligação completa", ylab = "Ponto de fusão")
```

```
#Cluster com ligação ward
```

```
res.hcW <- hclust(ds, method = "ward.D")
```

```
#Dendrograma
```

```
plot(res.hcW, labels = c("A", "B", "C", "D", "E"), cex = 0.6, hang = -1, main = "Dendrograma Ligação ward", ylab = "Ponto de fusão")
```

Correlação cofenética

A correlação cofenética é a correlação de Pearson entre os valores das distâncias originais e as distâncias nos níveis de fusão:

	D1	D2
12	0,750	0,625
13	0,625	0,625
14	0,875	0,625
15	1,000	0,625
23	0,125	0,125
24	0,375	0,250
25	0,250	0,250
34	0,500	0,250
35	0,375	0,250
45	0,125	0,125

Nesse exemplo, o coeficiente de correlação é igual a 0,9258

O mesmo pode ser feito para os outros métodos de ligação, para posteriormente compará-los e será considerado o melhor método aquele que produzir o maior coeficiente de corre