



Unidade VIII – Análise de Correspondência

ANÁLISE DE CORRESPONDÊNCIA SIMPLES

8.1. Introdução

Verificada a situação de associação entre variáveis categorizadas, pode ser de interesse aprofundar a análise para identificar relacionamentos entre as categorias das variáveis. Isso pode ser visualmente estudado por meio da técnica de Análise de Correspondência.

Análise de correspondência (AC) é uma técnica de análise exploratória de dados adequada para analisar dados categóricos, ou seja, dados que podem ser representados em tabelas bidimensionais (ou multidimensionais), levando em conta algumas medidas de correspondência entre linhas e colunas. A AC, basicamente, converte uma matriz de dados não negativos em um tipo particular de representação gráfica em que as linhas e colunas da matriz são simultaneamente representadas em dimensão reduzida, isto é, por pontos no gráfico. Na análise de correspondência, são traçados um ponto para cada linha e um ponto para cada coluna da tabela de contingência. Esses pontos são, na verdade, projeções das linhas e colunas da tabela de contingência em um espaço euclidiano bidimensional. O objetivo é preservar, tanto quanto possível, a relação das linhas (ou colunas) comum ao outro em um espaço bidimensional. Este método permite estudar as relações e semelhanças existentes entre:

- as categorias de linhas e entre as categorias de colunas de uma tabela de contingência,
- o conjunto de categorias de linhas e o conjunto de categorias de colunas.

A análise de correspondência pode ser considerada como um caso especial da análise de componentes principais (CP), dirigida a dados qualitativos organizados em tabelas de contingência e não a dados contínuos. O problema é análogo a encontrar o maior componente principal de um conjunto de I observações e J variáveis, com modificações devido à ponderação das observações e à métrica ponderada.

8.2. A tabela de contingência e a matriz de correspondência

Uma tabela de contingência com a categorias de linhas e b categorias de colunas, das variáveis A e B , respectivamente, são representadas na Tabela 8.1. Nas entradas das células n_{ij} estão as contagens das frequências para cada combinação de linhas e colunas. Os totais marginais apresentam a notação familiar com o ponto: $n_{i.} = \sum_{j=1}^b n_{ij}$ e $n_{.j} = \sum_{i=1}^a n_{ij}$. A frequência total geral é denotada por n , onde $n = \sum_{ij} n_{ij}$. Ou seja, ela é uma matriz de frequências absolutas, $\mathbf{N} = [n_{ij}]_{a \times b}$.

Tabela 8.1. Representação de uma Tabela de Contingência com a linhas e b colunas

		Colunas – Variável B				
		1	2	...	b	Total linha
Linhas – Variável A	1	n_{11}	n_{12}	...	n_{1b}	$n_{1.}$
	2	n_{21}	n_{22}	...	n_{2b}	$n_{2.}$
	$\vdots$				$\vdots$	$\vdots$
	a	n_{a1}	n_{a2}	...	n_{ab}	$n_{a.}$
Total coluna		$n_{.1}$	$n_{.2}$	...	$n_{.b}$	n

A partir da matriz $\mathbf{N}$ pode ser feita a matriz de frequências relativas $\mathbf{P} = (1/n)\mathbf{N}$, que é denominada *Matriz de correspondências*. As frequências n_{ij} da Tabela de contingência podem ser convertidas em frequências relativas p_{ij} dividindo por n : $p_{ij} = n_{ij}/n$. Cada linha ou coluna de $\mathbf{P}$ pode ser considerada um vetor de proporções (Tabela 8.2)

Tabela 8.2. Frequências relativas da Matriz de correspondências

		Colunas				
		1	2	...	b	Total linha
Linhas	1	p_{11}	p_{12}	...	p_{1b}	$p_{1.}$
	2	p_{21}	p_{22}	...	p_{2b}	$p_{2.}$
	$\vdots$				$\vdots$	$\vdots$

a	p_{a1}	p_{a2}	$\dots$	p_{ab}	p_a
Total coluna	$p_{.1}$	$p_{.2}$	$\dots$	$p_{.b}$	1

8.3. Massas e perfis

Da Tabela 8.2 definem-se os vetores de frequências relativas marginais (em relação ao total geral n) denominados **massas**. A massa da i -ésima linha é $n_{i.}/n$ e a massa da j -ésima coluna é $n_{.j}/n$. O vetor coluna de massas de linhas é $\mathbf{r} = \mathbf{P}\mathbf{j} = [p_{1.}, p_{2.}, \dots, p_{a.}]$, onde $\mathbf{j}$ é um vetor $a \times 1$ de elementos 1 e o vetor $\mathbf{c}' = \mathbf{j}'\mathbf{P} = [p_{.1}, p_{.2}, \dots, p_{.b}]$ é o vetor de massas de colunas, onde $\mathbf{j}'$ é um vetor $1 \times b$ de elementos 1.

O vetor $r'_i = [n_{i1}/n_{i.}, n_{i2}/n_{i.}, \dots, n_{ib}/n_{i.}] = [p_{i1}/p_{i.}, p_{i2}/p_{i.}, \dots, p_{ib}/p_{i.}]$ é chamado de **perfil linha**. Cada vetor r'_i representa uma realização da distribuição multinomial, condicionada à i -ésima categoria da variável A.

Analogamente, o vetor $c_j = [n_{1j}/n_{.j}, n_{2j}/n_{.j}, \dots, n_{aj}/n_{.j}] = [p_{1j}/p_{.j}, p_{2j}/p_{.j}, \dots, p_{aj}/p_{.j}]$, é chamado de **perfil coluna**.

O vetor $\mathbf{c}'$, que é o vetor de massas das colunas é também chamado de centroide dos perfis linha e do outro lado, o vetor de massas das linhas, $\mathbf{r}$, é chamado de centroide do perfil coluna.

Exemplo 8.1. (Hand et al. 1994, p. 12). A Tabela 8.3 apresenta o número de falhas no anel do pistão em cada um dos três pés em quatro compressores encontrados em um mesmo edifício (todos quatro compressores são orientados na mesma direção).

Tabela 8.3. Falhas no anel do pistão em compressores				
Compressor	Pés			
	Norte	Centro	Sul	Total linha
1	17	17	12	46
2	11	9	13	33
3	11	8	19	38
4	14	7	28	49
Total coluna	53	41	72	166

A matriz de correspondência na Tabela 8.4 foi criada dividindo-se cada elemento da Tabela 8.3 por $n = \sum_{ij} n_{ij} = 166$

Tabela 8.4. Matriz de correspondência				
Compressor	Pés			
	Norte	Centro	Sul	Total linha
1	17/166	17/166	12/166	46/166
2	11/166	9/166	13/166	33/166
3	11/166	8/166	19/166	38/166
4	14/166	7/166	28/166	49/166
Total coluna	53/166	41/166	72/166	1

As massas ou totais marginais de linhas e colunas são dadas por:

$$\mathbf{r} = \begin{pmatrix} 46/166 \\ 33/166 \\ 38/166 \\ 49/166 \end{pmatrix} \quad \text{e} \quad \mathbf{c}' = (53/166, 41/166, 72/166)$$

O perfil da 1ª linha será:

$$r'_1 = [n_{11}/n_{1.}, n_{12}/n_{1.}, n_{13}/n_{1.}] = [17/46, 17/46, 12/46]$$

Os perfis para as quatro linhas podem ser calculados e organizados em uma matriz de perfis de linha:

$$\mathbf{R} = \begin{pmatrix} 17/46 & 17/46 & 12/46 \\ 11/33 & 9/33 & 13/33 \\ 11/38 & 8/38 & 19/38 \\ 14/49 & 7/49 & 28/49 \end{pmatrix}$$

De forma similar os perfis de coluna podem ser calculados e organizados em uma matriz:

$$\mathbf{C} = \begin{pmatrix} 17/53 & 11/53 & 11/53 & 14/53 \\ 17/41 & 9/41 & 8/41 & 7/41 \\ 12/72 & 13/72 & 19/72 & 28/72 \end{pmatrix}$$

8.4. Teste de independência

A hipótese nula de independência de linha-coluna, $n_{ij} = (n_{i.} + n_{.j})/n$ é equivalente à hipótese de homogeneidade das linhas: $n_{1j}/n_{1.} = n_{2j}/n_{2.} = \dots = n_{aj}/n_{a.}$ ($j=1,\dots,b$).

Cada linha da matriz de dados pode ser vista como a realização de uma distribuição multinomial condicional ao respectivo total da linha. A estatística qui-quadrado usual, χ^2 que testa a hipótese nula de independência entre linhas e colunas, é expressa como segue:

$$\chi^2 = \sum_{i=1}^a \sum_{j=1}^b \frac{(n_{ij} - n_{i.}n_{.j}/n)^2}{(n_{i.}n_{.j}/n)}$$

Sob a hipótese de homogeneidade, a estatística χ^2 pode ser interpretada geometricamente como a diferença dos perfis linha (ou coluna) aos seus respectivos centroides ($\mathbf{c}'$ ou $\mathbf{r}$). A significância de χ^2 indica desvios significativos dos perfis linha em relação a seu centroide ou à hipótese de homogeneidade.

Se as variáveis A e B forem independentes, espera-se que as linhas da tabela de contingência tenham perfis similares, ou equivalentemente, que as colunas tenham perfis similares. Pode-se comparar os perfis linhas comparando cada perfil linha $\mathbf{r}_i'$ com o seu centroide, $\mathbf{c}'$ (vetor de massas das colunas) usando a versão alternativa da estatística qui-quadrado:

$$\chi^2 = \sum_{i=1}^a np_{i.} \sum_{j=1}^b \left[\left(\frac{p_{ij}}{p_{i.}} - p_{.j} \right)^2 / p_{.j} \right]$$

Que na sua forma matricial é dada por:

$$\chi^2 = \sum_{i=1}^a np_{i.} (\mathbf{r}_i - \mathbf{c})' \mathbf{D}_c^{-1} (\mathbf{r}_i - \mathbf{c})$$

onde $\mathbf{r}_i$ é o i -ésimo perfil de linha, $\mathbf{c}$ é a massa ou totais marginais das colunas, $\mathbf{D}_c$ é a uma matriz diagonal cujos elementos são as massas de coluna:

$$\mathbf{D}_c = \begin{pmatrix} p_{.1} & 0 & \dots & 0 \\ 0 & p_{.2} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & p_{.b} \end{pmatrix}$$

8.5. Distâncias e inércia

As distâncias entre os pontos da linha e as distâncias entre os pontos da coluna são significativas na AC. As distâncias entre dois perfis linha $\mathbf{r}_i$ e $\mathbf{r}_j$ são determinadas usando a métrica Euclidiana ponderada, chamada métrica ou distância qui-quadrado:

$$d_{ij}^2 = (\mathbf{r}_i - \mathbf{r}_j)' \mathbf{D}_c^{-1} (\mathbf{r}_i - \mathbf{r}_j)$$

Cada perfil linha está ponderado por um peso proporcional ao respectivo total da linha nos dados originais, correspondente aos $p_{i.}$, a massa da linha. Assim a distância qui-quadrado entre os perfis linha e o centroide fica:

$$d_c(\mathbf{r}_i, \mathbf{c}) = n \sum_{j=1}^b p_{i.} (\mathbf{r}_i - \mathbf{c})' \mathbf{D}_c^{-1} (\mathbf{r}_i - \mathbf{c})$$

A média ponderada dos quadrados das distâncias entre os perfis linha e seu centroide $\mathbf{c}$ é igual a estatística χ^2 , que testa a independência de linhas e colunas, dividida pelo total geral n . A quantidade χ^2/n é denominada de **inércia total** da matriz de dados. Para o exemplo obtém-se $\chi^2 = 11.722$ (com 6 gl), que apresenta p-valor = 0.0685, evidenciando que

existe ausência de independência entre pé e compressor apenas ao nível de 10% de significância. A inércia total é de $\chi^2/n = 11.722/166 = 0,071$.

Uma maneira de olhar a análise de correspondência é considerá-la como um método de decomposição da inércia total, identificando um número reduzido de dimensões que melhor representem uma nuvem de pontos. Levando esta ideia para o caso unidimensional com os eixos “estendidos”, o problema se resume em encontrar a linha que melhor se ajusta aos pontos (perfis). A melhor linha passa pelo centroide c que é um resumo adimensional (um ponto). Se a origem do gráfico é transferida para c , então a linha que melhor se ajusta é o autovetor principal da matriz assimétrica

$$Q = \sum_{j=1}^b p_{i.} (\mathbf{r}_i - \mathbf{c}) (\mathbf{r}_i - \mathbf{c})' \mathbf{D}_c^{-1} = (\mathbf{R} - \mathbf{J}\mathbf{c}')' \mathbf{D}_r (\mathbf{R} - \mathbf{J}\mathbf{c}')' \mathbf{D}_c^{-1}$$

onde $\mathbf{D}_r$ e $\mathbf{D}_c$ são as matrizes diagonais de massas de linha e de coluna, respectivamente, e $\mathbf{R}$ é matriz cujas linhas são os perfis de linha.

O traço da matriz Q é igual a χ^2/n , e seu conjunto de autovalores $\lambda_1, \lambda_2, \dots$, ou inércias principais, é uma decomposição da inércia total.

Podem ser calculadas as coordenadas dos pontos das linhas e pontos das colunas para uma representação bidimensional dos dados de uma tabela de contingência.

No R

```
library(ca)
fit = ca(Compressor)
print(fit) # resultado básico
summary(fit) # resultado estendido
fit$rowmass
fit$rowdist
fit$colcoord
fit$rownames
plot(fit) # mapa simétrico
plot(fit, mass = TRUE, contrib = "absolute", map =
      "rowgreen", arrows = c(FALSE, TRUE)) # mapa assimétrico
```

ANÁLISE DE CORRESPONDÊNCIA MÚLTIPLA (ACM)

A análise de correspondência múltipla (ACM) é uma técnica exploratória utilizada para mais de duas variáveis categóricas. Ela é usualmente vista como uma extensão da análise de correspondência simples. Pode também ser entendida como um caso especial da ACP (Análise de Componentes Principais), para mais de duas variáveis categóricas. Na ACM inicialmente, a matriz de dados é transformada em uma matriz indicadora, que explora a relação entre um conjunto de variáveis categóricas.

Por exemplo, considere o conjunto de dados de uma amostra com 10 observações e 3 variáveis categóricas ($\mathbf{Z}, \mathbf{Y}, \mathbf{W}$). Para facilitar cada uma das variáveis categóricas possui duas categorias de resposta, **1** e **2**:

Obs.	Z	Y	W
1	1	1	2
2	2	1	2
3	2	2	2
4	1	2	1
5	1	2	1
6	1	1	1
7	2	2	2
8	1	2	2
9	<u>1</u>	<u>1</u>	1
10	1	1	2

Para essa matriz de dados pode ser criada a matriz indicadora $\mathbf{X}$, com 10 observações e 3 variáveis categóricas ($\mathbf{Z}, \mathbf{Y}, \mathbf{W}$), subdivididas em 2 categorias por variável.

Matriz indicadora X

Obs.	z1	z2	y1	y2	w1	w2
1	1	0	1	0	1	0
2	0	1	1	0	1	0
3	0	1	0	1	1	0
4	1	0	0	1	0	1
5	1	0	0	1	0	1
6	1	0	1	0	0	1
7	0	1	0	1	1	0
8	1	0	0	1	1	0
9	1	0	1	0	0	1
10	1	0	1	0	1	0
Total	7	3	5	5	6	4

As informações contidas na matriz **X** permitem gerar a matriz Burt (**B**), que representa uma tabulação cruzada (produto interno) de todas as categorias e variáveis, ou seja, $\mathbf{B} = \mathbf{X}'\mathbf{X}$, cuja matriz é simétrica.

Matriz Burt (B)

	z1	z2	y1	y2	w1	w2
z1	<u>7</u>	0	4	3	3	4
z2	0	<u>3</u>	1	2	3	0
y1	4	1	<u>5</u>	0	3	2
y2	3	2	0	<u>5</u>	3	2
w1	3	3	3	3	<u>6</u>	0
w2	4	0	2	2	0	<u>4</u>

Além da simetria, na diagonal principal da matriz $\mathbf{B} = \{b_{kh}\}$ estão os totais de cada categoria. Ademais, a soma das categorias de cada variável deve ser exatamente ao número observações. Por exemplo, para a variável **Z**, o total de observações nas categorias z1 e z2 é 10, ou seja, $z1+z2=7+3=10$. Por outro lado, observa-se que a combinação entre as categorias de uma determinada variável exibe valores nulos. Por exemplo, não há observações na combinação z1 e z2 (em destaque em vermelho).

Descritas as propriedades da matriz Burt, observe que há J categorias de k variáveis categóricas, então a matriz de correspondência é análoga à versão simples, ou seja, podem ser calculados os perfis e massas e inércia

Os resultados em ACM são idênticos aos resultados para as coordenadas de coluna na versão simples da matriz indicadora. A interpretação dos valores das coordenadas, dos valores de qualidade e outras estatísticas são similares, porém se referindo à inércia total associada à matriz indicadora inteira.

Foram desenvolvidos outros métodos para analisar o relacionamento de variáveis categóricas com mais de duas categorias, como o método proposto por Greenacre (2006), conhecido como análise de correspondência conjunta (ACJ). Uma vez que tanto a matriz indicadora quanto a Burt inflam artificialmente as distâncias qui-quadrado entre os perfis de coluna e a inércia total (GOWER, 2006), a ACJ busca corrigir esse problema ao considerar somente os elementos fora da diagonal da matriz Burt. Tal técnica baseia-se em um método iterativo de mínimos quadrados.

Exemplo: Dados de estudantes sobre o perfil e investimentos.